语言模型

一、项目导论

1.1 nlp 项目的类别

nlp 项目的类别可分为四种：文本匹配问题、文本分类问题、序列标注问题（ner/词性/分词）、序列到序列问题（文本摘要/机器翻译/问答/对话）

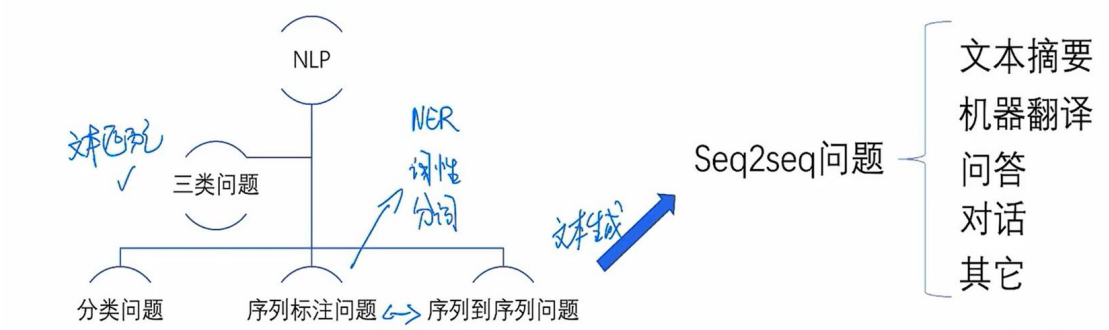

nlp 类别图

二、语言模型到 WordEmbedding

2.1 语言模型

(1) 如何表达一句话的好坏、合理与通顺？

答：我们采用概率的表达来表示，概率越高表示越通顺、合理。

- 今天欢迎同学们来到后厂理工学院学习课程。
- 今天欢迎同学们后厂理工学院来到学习课程。
- 今天欢迎同学们来到后厂理工学院课程学习。

$$P(s) = P(w_1 w_2 \dots w_n)$$

$$= P(w_1) P(w_2|w_1) P(w_3|w_1 w_2) \dots P(w_n|w_1, w_2 \dots w_{n-1})$$

其中，w_i 表示分词后的词，s 表示句子，采用联合概率表示，最终表示，当前词不仅自身相关，还与之前的所有词相关。

此外，引入马尔可夫假设，当前词只与上一个词相关，与其他词无关，这一种方式也叫 2-gram,如果相互独立，叫 1-gram；与前 2 个叫 3-gram...。

(2) 最初的神经网络语言模型（NNLM）结构？

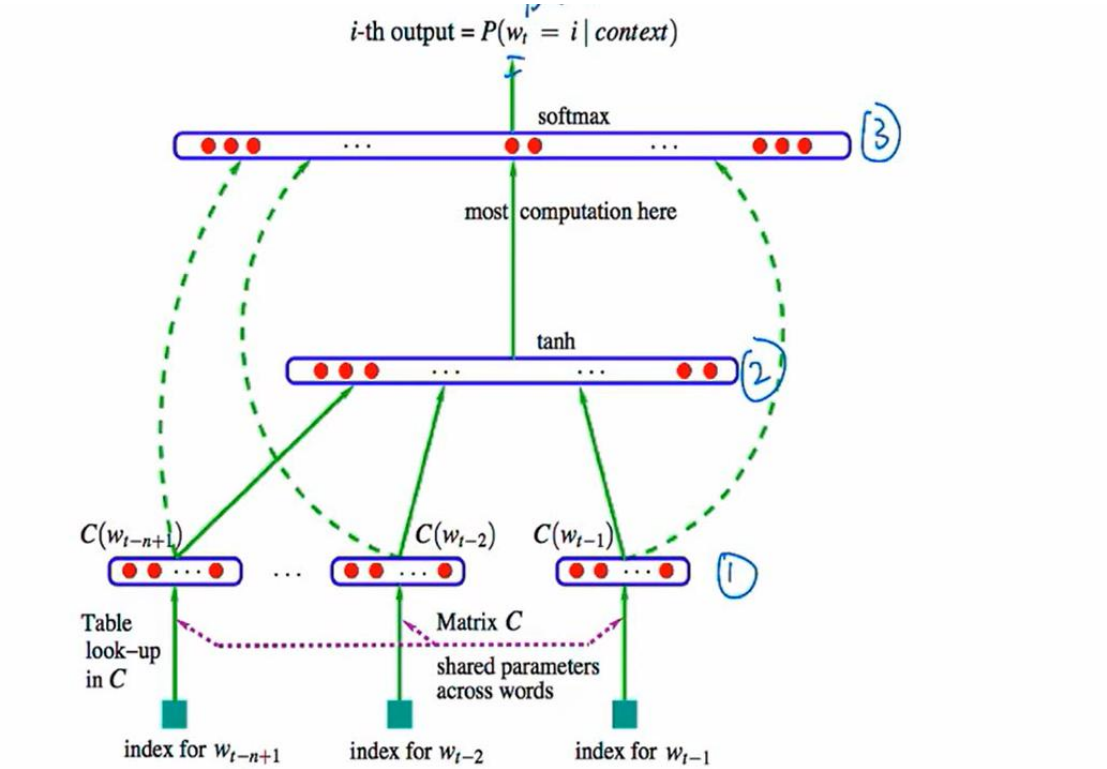

解释：总共分为 3 层：输入、隐层、输出；输入前 n-1 个 token 采用编码（one-hot），乘以矩阵 C，得到词的表征，将所有表征 concat,传入隐层，输出层采用 softmax 求出词概率。

(3) 语言的表达方式？

①离散的表达方式：one-hot(先进行分词，构建 vocab,求 one-hot)

缺陷：太稀疏、缺乏语义之间的相关性

②通过上下文表达（通过周围词表达中间词）

③word2vec（词向量方式）

(4) Word2vec

Word embeddinng 实现将一个词嵌入到一个空间的目的；具体：需要一个巨大的词表库，词表中每一个词可以向量表示，有一个中心词 c 和一个输出词 o，计算 o 与 c 的相似度，保证同时出现的概率最大。

1.4.1 Word2vec 的目标函数：

$$L(\theta)=\prod_{t=1}^{T}\prod_{-m\le j\le m,\ j\neq 0} P(w_{t+j}\mid w_t;\theta)$$

θ：参数

目的是根据中心词输入 w_t 与参数 θ，保证周围词乘积的概率最大，遍历所有中心词 w_t 进行连乘即可，即 L(θ)越大越好。

乘积可以表示相似度，中心词来预测周围词的概率可表示为：

$$P(O|C) = Softmax(u_o^T v_c)$$

损失函数则取负数，再求 log（保证浮点数不会上下溢）

$$J(\theta) = -\frac{1}{T}\log(L(\theta))$$

1.4.2 词向量的模型的设计

（1）Skip-gram 模型

Skip-gram 目的是采用中心词来预测周围词，数据格式采用['中心词',('左周围词','右周围词')]，超参数 window 为滑窗，此时为 1；

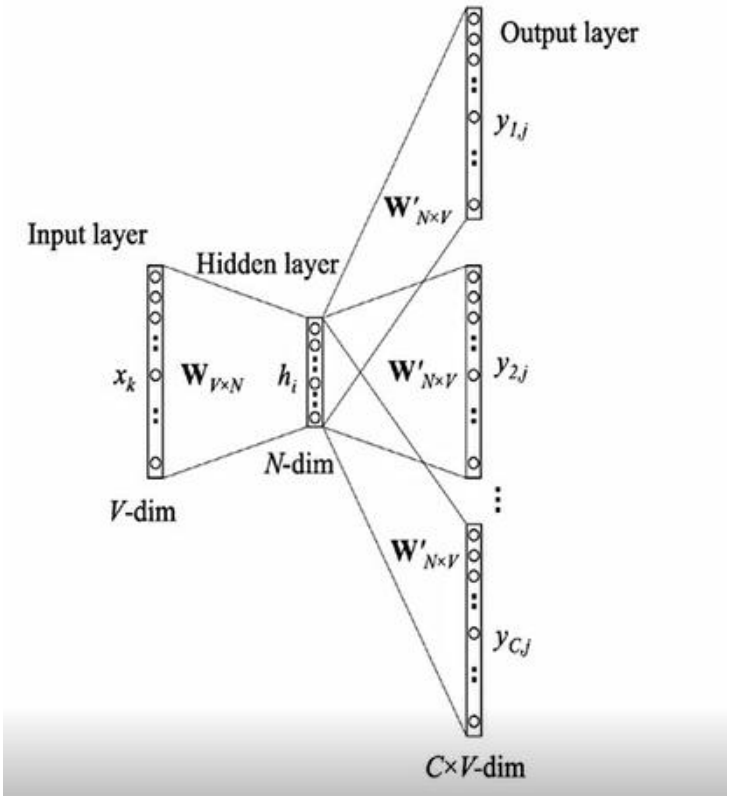

Skip-gram 结构图

解析：输入的表征采用 one-hot，隐层为一个矩阵，即词向量，输出层为周围词的预测，loss 采用交叉熵，进行 window*2 次反向传播。

（2）cbow 模型

cbow 是一个连续的词袋模型，目的是采用周围的词来预测中心词，数据格式与 skip-gram 相反，与周围词相乘的 W 都是同一个 W，即词向量，对所有周围进行加权平均，再传入隐层，最后预测中心词。

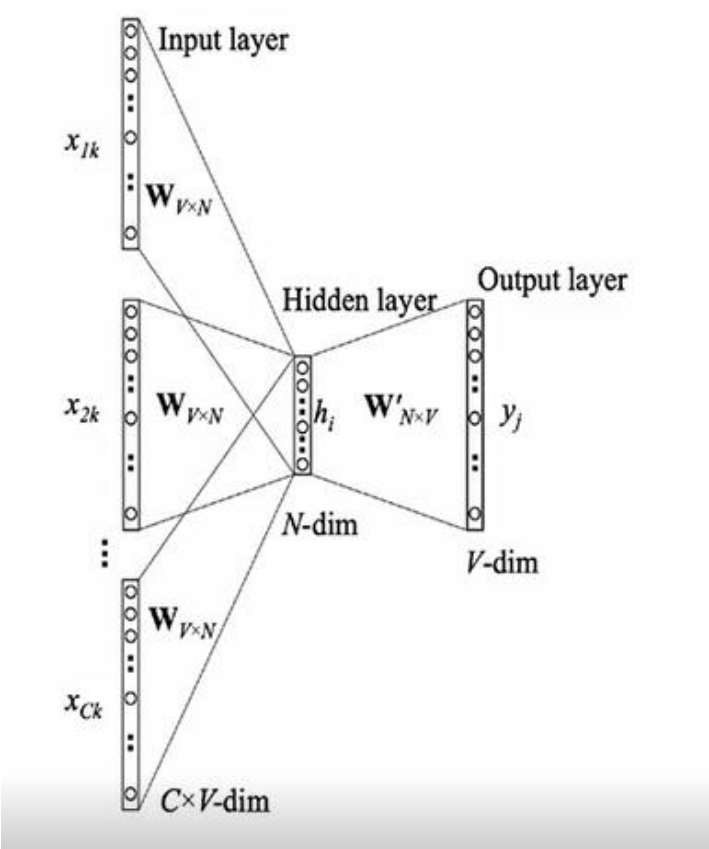

cbow 结构图

（3）skip-gram 与 cbow 的对比

①时间复杂度

Skip-gram 的时间复杂度为 O(k*v),因为需要 k 次反向传播，cbow 的时间复杂度为:O(v)

②周围词影响

Skip-gram 的效果较好一些，因为 cbow 需要周围词进行加权平均，收到许多周围词影响，效果比较差一点。

1.4.3 模型的改进与优化

为什么要进行优化？

答：在进行 skip-gram 或者 cbow 的时候，最后一层均采用 softmax 计算，当 vocab 很大时，softmax 分母的计算将会非常大，因此对最后的计算进行优化。

（1）Huffman Tree（哈夫曼树）

- 正常树与哈夫曼树的比较

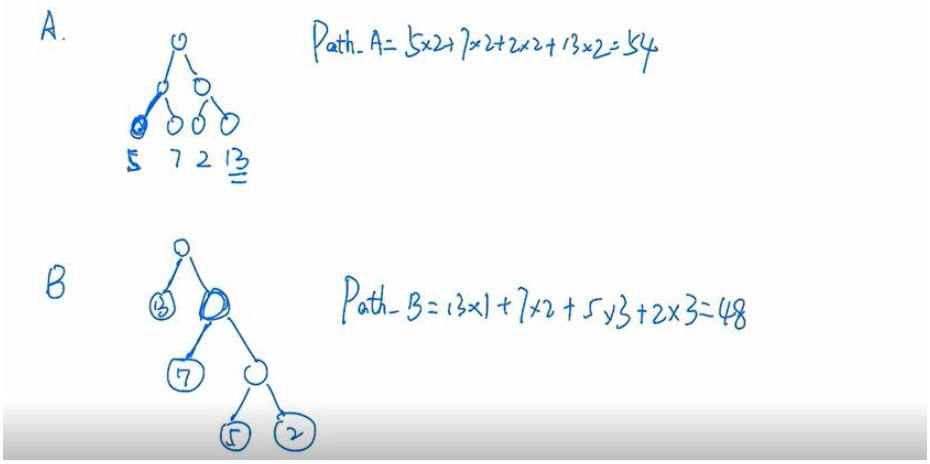

一般的树没有考虑词频，类似 A 树；然而哈夫曼树是路径最路径最短的树，会将词频高放在顶层叶子，词频低的放在底层叶子。

- 哈夫曼编码

在哈夫曼树构建之后，将左节点置为 0，右节点置为 1，寻求路径的编码成为哈夫曼编码；

- Logistic Regression

采用逻辑回归来判断当前节点是往左走，还是往右走。

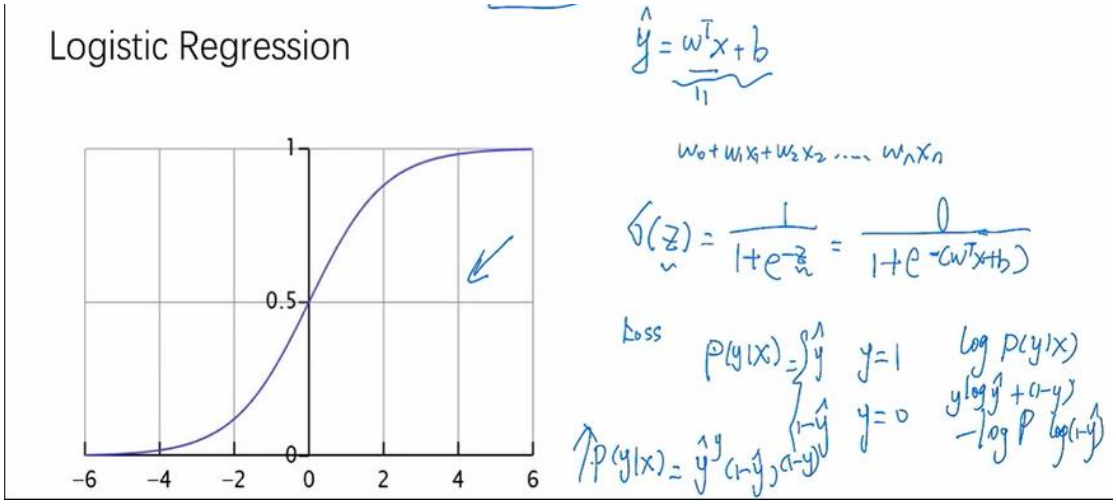

逻辑回归图

- Hierarchical Softmax

Hierarchical Softmax 则是将逻辑回归嵌入到哈夫曼树中；词表库一开始就是固定，说明哈夫曼树一开始也是定死的。所以一旦构建好哈夫曼树，后面的计算将会很快。

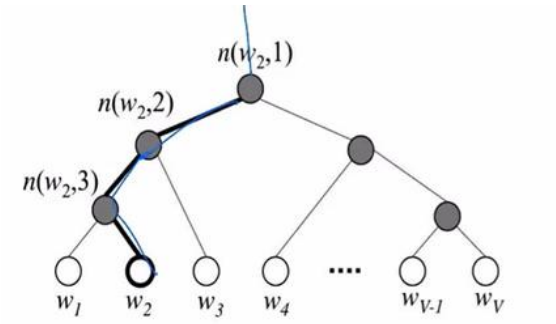

优点：计算复杂度会降至 O(log2V)、参与计算的参数更少
缺点：更偏向于高频词

（1）Negative Sampling（负采样）

负采样是每次让一个训练样本仅仅更新一小部分的权重；其中正样本为待预测词，负样本随机选择 k 个，小规模下，5<=k<=20,大规模下，2<=k<=5;
负采样的选择与词频一定的关联，概率公式如下：

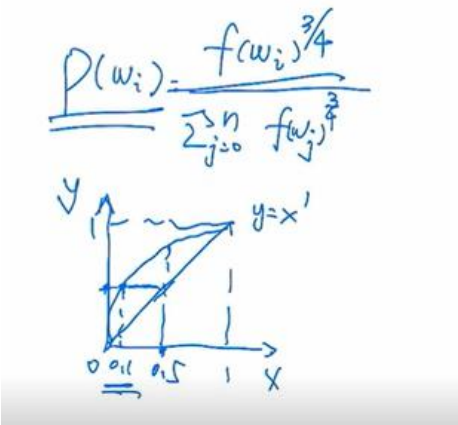

为何采用的词频的 3/4 呢？
答：上图可得，词频的 3/4 提升了低频词被选中的概率。

三、词向量的实践与应用

- 采用 gensim 调用词向量，具体百度
- 采用 AnnoyIndex 求词的最相似词检索，时间大大降低
  原理：给数据建立 KD-tree 的索引空间
  代码：
  1、根据词向量构建 KD-树

2、根据新的词向量，查找与它最相似的 k 个词向量对应的 id